

# Job 与 CronJob 控制器

接下来给大家介绍另外一类资源对象：**Job**，我们在日常的工作中经常都会遇到一些需要进行批量数据处理和分析的需求，当然也会有按时间来进行调度的工作，在我们的 Kubernetes 集群中为我们提供了 **Job** 和 **CronJob** 两种资源对象来应对我们的这种需求。

**Job** 负责处理任务，即仅执行一次的任务，它保证批处理任务的一个或多个 Pod 成功结束。而 **CronJob** 则就是在 **Job** 上加上了时间调度。

## Job

我们用 **Job** 这个资源对象来创建一个如下所示的任务，该任务负责计算  $\pi$  到小数点后 2000 位，并将结果打印出来，此计算大约需要 10 秒钟完成。对应的资源清单如下所示：

```
# job-pi.yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: pi
spec:
  template:
    spec:
      containers:
        - name: pi
          image: perl:5.34.0
          command: ["perl", "-Mbignum=bpi", "-wle", "print bpi(2000)"]
      restartPolicy: Never
  backoffLimit: 4
```

我们可以看到 **Job** 中也是一个 Pod 模板，和之前的 Deployment、StatefulSet 之类的是一致的，只是 Pod 中的容器要求是一个任务，而不是一个常驻前台的进程了，因为需要退出，另外值得注意的是 **Job** 的 **RestartPolicy** 仅支持 **Never** 和 **OnFailure** 两种，不支持 **Always**，我们知道 **Job** 就相当于来执行一个批处理任务，执行完就结束了，如果支持 **Always** 的话是不是就陷入了死循环了？

直接创建这个 Job 对象：

```
* → kubectl apply -f job-pi.yaml
job.batch/pi created
* → kubectl get job
NAME      COMPLETIONS  DURATION  AGE
pi        0/1           6s        6s
* → kubectl get pods
NAME          READY  STATUS             RESTARTS  AGE
pi-4krqt     0/1    ContainerCreating  0         14s
```

**Job** 对象创建成功后，我们可以查看下对象的详细描述信息：

```
* → kubectl describe job pi
Name:          pi
Namespace:     default
```

```

Selector:      controller-uid=951b4719-8f6b-4481-b15a-99d865c81840
Labels:        controller-uid=951b4719-8f6b-4481-b15a-99d865c81840
                job-name=pi
Annotations:    batch.kubernetes.io/job-tracking:
Parallelism:    1
Completions:    1
Completion Mode: NonIndexed
Start Time:      Thu, 15 Dec 2022 15:33:09 +0800
Pods Statuses:  1 Active (0 Ready) / 0 Succeeded / 0 Failed
Pod Template:
  Labels:  controller-uid=951b4719-8f6b-4481-b15a-99d865c81840
           job-name=pi
  Containers:
    pi:
      Image:      perl:5.34.0
      Port:        <none>
      Host Port:    <none>
      Command:
        perl
        -Mbignum=bpi
        -wle
        print bpi(2000)
      Environment: <none>
      Mounts:       <none>
  Volumes:          <none>
Events:
  Type      Reason              Age   From          Message
  ----      -
  Normal    SuccessfulCreate     50s   job-controller Created pod: pi-4krqt

```

可以看到，Job 对象在创建后，它的 Pod 模板，被自动加上了一个 `controller-uid=< 一个随机字符串 >` 这样的 Label 标签，而这个 Job 对象本身，则被自动加上了这个 Label 对应的 Selector，从而保证了 Job 与它所管理的 Pod 之间的匹配关系。而 Job 控制器之所以要使用这种携带了 UID 的 Label，就是为了避免不同 Job 对象所管理的 Pod 发生重合。

我们可以看到隔一会儿后 Pod 变成了 `Completed` 状态，这是因为容器的任务执行完成正常退出了，我们可以查看对应的日志：

```
* → kubectl logs pi-4krgt
```

```
3.14159265358979323846264338327950288419716939937510582097494459230781640628620899862803
4825342117067982148086513282306647093844609550582231725359408128481117450284102701938521
1055596446229489549303819644288109756659334461284756482337867831652712019091456485669234
6034861045432664821339360726024914127372458700660631558817488152092096282925409171536436
7892590360011330530548820466521384146951941511609433057270365759591953092186117381932611
7931051185480744623799627495673518857527248912279381830119491298336733624406566430860213
9494639522473719070217986094370277053921717629317675238467481846766940513200056812714526
3560827785771342757789609173637178721468440901224953430146549585371050792279689258923542
0199561121290219608640344181598136297747713099605187072113499999983729780499510597317328
1609631859502445945534690830264252230825334468503526193118817101000313783875288658753320
8381420617177669147303598253490428755468731159562863882353787593751957781857780532171226
8066130019278766111959092164201989380952572010654858632788659361533818279682303019520353
0185296899577362259941389124972177528347913151557485724245415069595082953311686172785588
9075098381754637464939319255060400927701671139009848824012858361603563707660104710181942
9555961989467678374494482553797747268471040475346462080466842590694912933136770289891521
0475216205696602405803815019351125338243003558764024749647326391419927260426992279678235
4781636009341721641219924586315030286182974555706749838505494588586926995690927210797509
3029553211653449872027559602364806654991198818347977535663698074265425278625518184175746
7289097777279380008164706001614524919217321721477235014144197356854816136115735255213347
5741849468438523323907394143334547762416862518983569485562099219222184272550254256887671
7904946016534668049886272327917860857843838279679766814541009538837863609506800642251252
0511739298489608412848862694560424196528502221066118630674427862203919494504712371378696
09563643719172874677646575739624138908658326459958133904780275901
```

```
* → kubectl get pod
```

NAME	READY	STATUS	RESTARTS	AGE
pi-4krgt	0/1	Completed	0	11m

上面我们这里的 Job 任务对应的 Pod 在运行结束后，会变成 **Completed** 状态，但是如果执行任务的 Pod 因为某种原因一直没有结束怎么办呢？同样我们可以在 Job 对象中通过设置字段 **spec.activeDeadlineSeconds** 来限制任务运行的最长时间，比如：

```
spec:
  activeDeadlineSeconds: 100
```

那么当我们的任务 Pod 运行超过了 100s 后，这个 Job 的所有 Pod 都会被终止，并且的终止原因会变成 **DeadlineExceeded**。

如果的任务执行失败了，会怎么处理呢，这个和定义的 **restartPolicy** 有关系，比如定义如下所示的 Job 任务，定义 **restartPolicy: Never** 的重启策略：

```
# job-failed-demo.yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: job-failed-demo
spec:
  template:
    spec:
      containers:
        - name: test-job
          image: busybox
          command: ["echo123", "test failed job!"]
      restartPolicy: Never
```

直接创建上面的资源对象：

```
* → kubectl apply -f job-failed-demo.yaml
job.batch/job-failed-demo created
* → kubectl get pod
```

NAME	READY	STATUS	RESTARTS	AGE
job-failed-demo-5hrdj	0/1	StartError	0	55s
job-failed-demo-bqxs	0/1	StartError	0	49s
job-failed-demo-m29nr	0/1	StartError	0	39s
job-failed-demo-r8cfz	0/1	StartError	0	44s
job-failed-demo-v6228	0/1	StartError	0	35s
job-failed-demo-v7q2c	0/1	StartError	0	30s
job-failed-demo-zqk68	0/1	StartError	0	25s

可以看到当我们设置成 **Never** 重启策略的时候，Job 任务执行失败后会不断创建新的 Pod，但是不会一直创建下去，会根据 **spec.backoffLimit** 参数进行限制，默认为 6，通过该字段可以定义重建 Pod 的次数。

但是如果设置的 **restartPolicy: OnFailure** 重启策略，则当 Job 任务执行失败后不会创建新的 Pod 出来，只会不断重启 Pod，比如将上面的 Job 任务 **restartPolicy** 更改为 **OnFailure** 后查看 Pod：

```
* → kubectl get pods
```

NAME	READY	STATUS	RESTARTS	AGE
job-failed-demo-6l8vn	0/1	CrashLoopBackOff	3 (22s ago)	77s

除此之外，我们还可以通过设置 **spec.parallelism** 参数来进行并行控制，该参数定义了一个 Job 在任意时间最多可以有多少个 Pod 同时运行。并行性请求 (**spec.parallelism**) 可以设置为任何非负整数，如果未设置，则默认为 1，如果设置为 0，则 Job 相当于启动之后便被暂停，直到此值被增加。

**spec.completions** 参数可以定义 Job 至少要完成的 Pod 数目。如下所示创建一个新的 Job 任务，设置允许并行数为 2，至少要完成的 Pod 数为 8：

```
# job-para-demo.yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: job-para-test
spec:
```

```
parallelism: 2
completions: 8
template:
  spec:
    containers:
    - name: test-job
      image: busybox
      command: ["echo", "test paralle job!"]
      restartPolicy: Never
```

创建完成后查看任务状态:

```
* → kubectl get pods
NAME                                READY   STATUS              RESTARTS   AGE
job-para-test-qcmms                 0/1     ContainerCreating   0           3s
job-para-test-rsdbv                 0/1     ContainerCreating   0           3s
* → kubectl get job
NAME            COMPLETIONS   DURATION   AGE
job-para-test   8/8           15s        15s
* → kubectl get pod
NAME                                READY   STATUS      RESTARTS   AGE
job-para-test-bzpj7                 0/1     Completed   0           31s
job-para-test-c2zll                 0/1     Completed   0           23s
job-para-test-c47fg                 0/1     Completed   0           17s
job-para-test-hsf5p                 0/1     Completed   0           25s
job-para-test-q9j6j                 0/1     Completed   0           29s
job-para-test-qcmms                 0/1     Completed   0           36s
job-para-test-qfmq7                 0/1     Completed   0           19s
job-para-test-rsdbv                 0/1     Completed   0           36s
```

可以看到一次可以有 2 个 Pod 同时运行, 需要 8 个 Pod 执行成功, 如果不是 8 个成功, 那么会根据 `restartPolicy` 的策略进行处理, 可以认为是一种检查机制。

此外带有确定完成计数的 Job, 即 `.spec.completions` 不为 `null` 的 Job, 都可以在其 `.spec.completionMode` 中设置完成模式:

- **NonIndexed (默认值)**: 当成功完成的 Pod 个数达到 `.spec.completions` 所设值时认为 Job 已经完成。换言之, 每个 Job 完成事件都是独立无关且同质的。要注意的是, 当 `.spec.completions` 取值为 `null` 时, Job 被默认处理为 **NonIndexed** 模式。
- **Indexed**: Job 的 Pod 会获得对应的完成索引, 取值为 0 到 `.spec.completions-1`, 该索引可以通过三种方式获取:
  - Pod 的注解 `batch.kubernetes.io/job-completion-index`。
  - 作为 Pod 主机名的一部分, 遵循模式 `$(job-name)-$(index)`。当你同时使用带索引的 Job (Indexed Job) 与服务 (Service), Job 中的 Pod 可以通过 DNS 使用确切的主机名互相寻址。
  - 对于容器化的任务, 在环境变量 `JOB_COMPLETION_INDEX` 中可以获得。

当每个索引都对应一个成功完成的 Pod 时, Job 被认为是已完成的。

## 索引完成模式

下面我们将运行一个使用多个并行工作进程的 Kubernetes Job，每个 worker 都是在自己的 Pod 中运行的不同容器。Pod 具有控制平面自动设置的索引编号（index number），这些编号使得每个 Pod 能识别出要处理整个任务的哪个部分。

Pod 索引在注解 `batch.kubernetes.io/job-completion-index` 中呈现，具体表示为一个十进制值字符串。为了让容器化的任务进程获得此索引，我们可以使用 downward API 机制来获取注解的值。而且控制平面会自动设置 Downward API 在 `JOB_COMPLETION_INDEX` 环境变量中暴露索引。

我们这里创建一个如下所示的 Job 资源清单文件：

```
# job-indexed.yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: indexed-job
spec:
  completions: 5
  parallelism: 3
  completionMode: Indexed
  template:
    spec:
      restartPolicy: Never
      initContainers:
        - name: "input"
          image: "bash"
          command:
            - "bash"
            - "-c"
            - |
              items=(foo bar baz qux xyz)
              echo ${items[$JOB_COMPLETION_INDEX]} > /input/data.txt
      volumeMounts:
        - mountPath: /input
          name: input
      containers:
        - name: "worker"
          image: "busybox"
          command:
            - "rev"
            - "/input/data.txt"
          volumeMounts:
            - mountPath: /input
              name: input
      volumes:
        - name: input
          emptyDir: {}
```

在该资源清单中我们设置了 `completionMode: Indexed`，表示这是一个 `Indexed` 完成模式的 Job 任务。这里我们还使用了 Job 控制器为所有容器设置的内置 `JOB_COMPLETION_INDEX` 环境变量。Init 容器将索引映射到一个静态值，并将其写入一个文件，该文件通过 `emptyDir` 卷与运行 worker 的容器共享。

`rev` (reverse) 命令用于将文件中的每行内容以字符为单位反序输出，即第一个字符最后输出，最后一个字符最先输出，以此类推。

直接创建该资源对象即可：

```
* → kubectl apply -f job-indexed.yaml
* → kubectl get job
```

NAME	COMPLETIONS	DURATION	AGE
indexed-job	0/5	4s	4s

当你创建此 Job 时，控制平面会创建一系列 Pod，你指定的每个索引都会运行一个 Pod。`.spec.parallelism` 的值决定了一次可以运行多少个 Pod，而 `.spec.completions` 决定了 Job 总共创建了多少个 Pod。

因为 `.spec.parallelism` 小于 `.spec.completions`，所以控制平面在启动更多 Pod 之前，将等待第一批的某些 Pod 完成。

```
* → kubectl get pods
```

NAME	READY	STATUS	RESTARTS	AGE
indexed-job-0-th2ks	0/1	Init:0/1	0	6s
indexed-job-1-8jbrp	0/1	Init:0/1	0	6s
indexed-job-2-zpv67	0/1	Init:0/1	0	6s

```
* → kubectl get pods
```

NAME	READY	STATUS	RESTARTS	AGE
indexed-job-0-th2ks	0/1	Completed	0	63s
indexed-job-1-8jbrp	0/1	Completed	0	63s
indexed-job-2-zpv67	0/1	Completed	0	63s
indexed-job-3-khcq8	0/1	Completed	0	26s
indexed-job-4-nzdhr	0/1	Completed	0	24s

创建 Job 后，稍等片刻，就能检查进度：

```
* → kubectl describe jobs/indexed-job
```

Name: indexed-job  
Namespace: default  
Selector: controller-uid=06708c09-0432-4fac-bd5c-f0b3041bf9b7  
Labels: controller-uid=06708c09-0432-4fac-bd5c-f0b3041bf9b7  
job-name=indexed-job  
Annotations: batch.kubernetes.io/job-tracking:  
Parallelism: 3  
Completions: 5  
Completion Mode: Indexed  
Start Time: Thu, 15 Dec 2022 16:12:38 +0800  
Completed At: Thu, 15 Dec 2022 16:13:28 +0800  
Duration: 50s  
Pods Statuses: 0 Active (0 Ready) / 5 Succeeded / 0 Failed  
Completed Indexes: 0-4  
# .....  
Events:

Type	Reason	Age	From	Message
----	-----	----	----	-----



Normal	SuccessfulCreate	100s	job-controller	Created pod: indexed-job-0-th2ks
Normal	SuccessfulCreate	100s	job-controller	Created pod: indexed-job-2-zpv67
Normal	SuccessfulCreate	100s	job-controller	Created pod: indexed-job-1-8jbrp
Normal	SuccessfulCreate	63s	job-controller	Created pod: indexed-job-3-khcq8
Normal	SuccessfulCreate	61s	job-controller	Created pod: indexed-job-4-nzdhr
Normal	Completed	50s (x2 over 50s)	job-controller	Job completed

这里我们使用的每个索引的自定义值运行 Job，我们可以检查其中一个 Pod 的输出：

```
❖ → kubectl logs indexed-job-3-khcq8
xuq
```

我们在初始化容器中执行了如下所示的命令：

```
items=(foo bar baz qux xyz)
echo ${items[$JOB_COMPLETION_INDEX]} > /input/data.txt
```

当 `JOB_COMPLETION_INDEX=3` 的时候表示我们将 `items[3]` 的 `qux` 值写入到了 `/input/data.txt` 文件中，然后通过 volume 共享，在主容器中我们通过 `rev` 命令将其反转，所以输出结果就位 `xuq` 了。

上面我们这个示例中每个 Pod 只做一小部分工作（反转一个字符串）。在实际工作中肯定比这复杂，比如你可能会创建一个基于场景数据制作 60 秒视频任务的 Job，此视频渲染 Job 中的每个工作项都将渲染该视频剪辑的特定帧，索引完成模式意味着 Job 中的每个 Pod 都知道通过从剪辑开始计算帧数，来确定渲染和发布哪一帧，这样就可以大大提高工作效率。

## CronJob

**CronJob** 其实就是在 **Job** 的基础上加上了时间调度，我们可以在给定的时间点运行一个任务，也可以周期性地在此时间点运行。这个实际上和我们 Linux 中的 **crontab** 就非常类似了。

一个 **CronJob** 对象其实就对应中 **crontab** 文件中的一行，它根据配置的时间格式周期性地运行一个 **Job**，格式和 **crontab** 也是一样的。

**crontab** 的格式为：分 时 日 月 星期 要运行的命令。

```
# _____ 分钟 (0 - 59)
# _____ 小时 (0 - 23)
# _____ 月的某天 (1 - 31)
# _____ 月份 (1 - 12)
# _____ 周的某天 (0 - 6) (周日到周一；在某些系统上，7 也是星期日)
# _____ 或者是 sun, mon, tue, web, thu, fri, sat
# * * * * *
```

- 第 1 列分钟 0 ~ 59



- 第 2 列小时 0 ~ 23
- 第 3 列日 1 ~ 31
- 第 4 列月 1 ~ 12
- 第 5 列星期 0 ~ 7 (0 和 7 表示星期天)
- 第 6 列要运行的命令

所有 CronJob 的 schedule 时间都是基于 `kube-controller-manager` 的时区，如果你的控制平面在 Pod 中运行了 `kube-controller-manager`，那么为该容器所设置的时区将会决定 CronJob 的控制器所使用的时区。官方并不支持设置如 `CRON_TZ` 或者 `TZ` 等变量，这两个变量是用于解析和计算下一个 Job 创建时间所使用的内部库中一个实现细节，不建议在生产集群中使用它。

但是如果在 `kube-controller-manager` 中启用了 `CronJobTimeZone` 这个 Feature Gates，那么我们就可以为 CronJob 指定一个时区（如果你没有启用该特性门控，或者你使用的是不支持试验性时区功能的 Kubernetes 版本，集群中所有 CronJob 的时区都是未指定的）。启用该特性后，你可以将 `spec.timeZone` 设置为有效时区名称。

现在，我们用 `CronJob` 来管理我们上面的 `Job` 任务，定义如下所示的资源清单：

```
# cronjob-demo.yaml
apiVersion: batch/v1
kind: CronJob
metadata:
  name: cronjob-demo
spec:
  schedule: "*/1 * * * *"
  jobTemplate:
    spec:
      template:
        spec:
          restartPolicy: OnFailure
          containers:
            - name: hello
              image: busybox
              args:
                - "bin/sh"
                - "-c"
                - "for i in 9 8 7 6 5 4 3 2 1; do echo $i; done"
```

这里的 Kind 变成了 `CronJob` 了，要注意的是 `.spec.schedule` 字段是必须填写的，用来指定任务运行的周期，格式就和 `crontab` 一样，另外一个字段是 `.spec.jobTemplate`，用来指定需要运行的任务，格式当然和 `Job` 是一致的。还有一些值得我们关注的字段 `.spec.successfulJobsHistoryLimit`（默认为 3）和 `.spec.failedJobsHistoryLimit`（默认为 1），表示历史限制，是可选的字段，指定可以保留多少完成和失败的 `Job`。然而，当运行一个 `CronJob` 时，`Job` 可以很快就堆积很多，所以一般推荐设置这两个字段的值，如果设置限制的值为 0，那么相关类型的 `Job` 完成后将不会被保留。

我们直接新建上面的资源对象：

```
* → kubectl apply -f cronjob-demo.yaml
cronjob "cronjob-demo" created
```

然后可以查看对应的 `Cronjob` 资源对象：

```
* → kubectl get cronjob
```

NAME	SCHEDULE	SUSPEND	ACTIVE	LAST SCHEDULE	AGE
cronjob-demo	*/* * * * *	False	1	2s	12s

稍微等一会儿查看可以发现多了几个 Job 资源对象，这个就是因为上面我们设置的 CronJob 资源对象，每 1 分钟执行一个新的 Job：

```
* → kubectl get job
```

NAME	COMPLETIONS	DURATION	AGE
cronjob-demo-27851555	1/1	7s	2m30s
cronjob-demo-27851556	1/1	7s	90s
cronjob-demo-27851557	1/1	6s	30s

```
* → kubectl get pods
```

NAME	READY	STATUS	RESTARTS	AGE
cronjob-demo-27851555-9x7hr	0/1	Completed	0	2m43s
cronjob-demo-27851556-9tdpl	0/1	Completed	0	103s
cronjob-demo-27851557-n6jdz	0/1	Completed	0	43s

这个就是 CronJob 的基本用法，一旦不再需要 CronJob，我们可以使用 kubectl 命令删除它：

```
* → kubectl delete cronjob cronjob-demo  
cronjob "cronjob-demo" deleted
```

不过需要注意的是这将会终止正在创建的 Job，但是运行中的 Job 将不会被终止，不会删除 Job 或 它们的 Pod。

思考：那如果我们想要在每个节点上去执行一个 Job 或者 Cronjob 又该怎么来实现呢？